POSTECH IA FOR DEVS | TECH CHALLENGE - FASE 1

Sistema Inteligente de Suporte ao Diagnóstico Citológico e Triagem Oncológica

Link do Repositório Git:	https://github.com/brunomirandadev/pos-tech-ia-devs-tc-fase1.git
Link do Dataset (Kaggle):	https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data
Vídeo de Demonstração (YouTube/Vimeo):	**[Inserir Link do Vídeo Demonstrativo aqui - até 15 min]**

1. Contextualização do Problema Hospitalar

Em hospitais universitários e centros de referência oncológica, o volume contínuo de biópsias por Punção Aspirativa por Agulha Fina (PAAF) impõe um desafio crítico aos médicos patologistas. A análise morfológica visual de cada lâmina exige extremo rigor técnico e tempo substancial, gerando filas de espera onde dias de atraso no início da intervenção médica podem comprometer o prognóstico do paciente. A presente solução estabelece um **Sistema de Suporte à Decisão Clínica (CDSS - *Clinical Decision Support System*)** com aprendizado de máquina para realizar a triagem preliminar automatizada, ordenar prioridades de atendimento por gravidade e oferecer uma segunda opinião quantitativa e explicável.

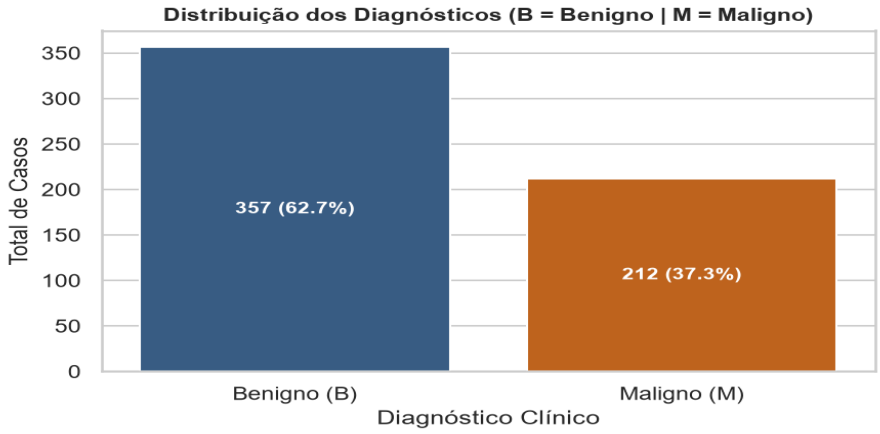
DIRETRIZ ÉTICA OBRIGATÓRIA: *O algoritmo atua estritamente como triagem e suporte auxiliar. A interpretação definitiva, o cruzamento com o histórico do paciente e a* ***palavra final sobre o laudo cabem sempre e exclusivamente ao médico especialista****.*

2. Análise Exploratória de Dados (EDA)

A base utilizada é a *Wisconsin Diagnostic Breast Cancer (WDBC)*, compreendendo **569 exames citológicos** e 30 atributos morfológicos extraídos de imagens digitalizadas dos núcleos celulares. Não foram identificados dados ausentes nas colunas preditoras nem registros duplicados.

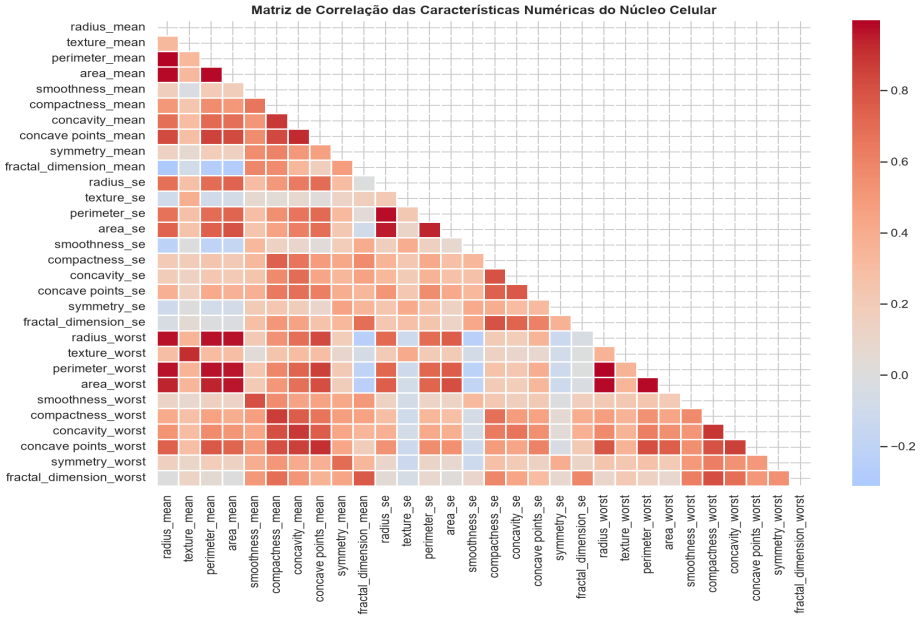
2.1. Distribuição da Variável Alvo e Implicações de Amostragem

A base apresenta 357 casos Benignos (62.7%) e 212 casos Malignos (37.3%). Esse desbalanceamento moderado exige a aplicação de **amostragem estratificada (*stratify*)** em todas as etapas de partição dos dados, assegurando representatividade idêntica da patologia.



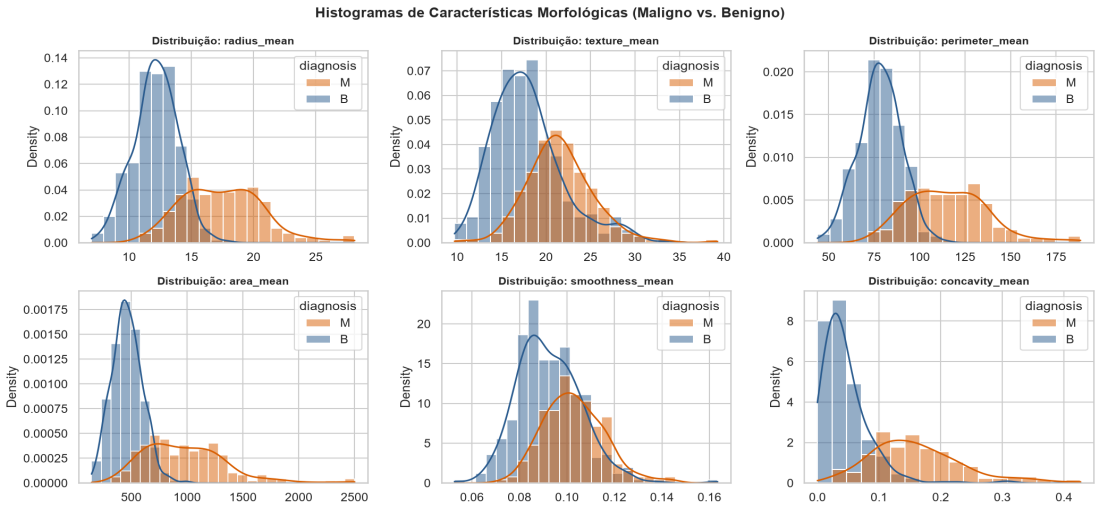
2.2. Matriz de Correlação e Multicolinearidade

A análise de correlação linear (Pearson) revelou níveis extremos de multicolinearidade (r > 0.98) entre medidas geométricas interdependentes (como *radius*, *perimeter* e *area*). Em algoritmos lineares, a colinearidade distorce coeficientes pontuais, justificando a aplicação de penalização regularizada (L2) e técnicas robustas de interpretabilidade aditiva como o **SHAP**.



2.3. Distribuições Morfológicas e Discriminação de Classes

Os histogramas demonstram que núcleos malignos (laranja) apresentam sistemático deslocamento para valores mais altos de raio, área e concavidade, refletindo o gigantismo e o polimorfismo nuclear típico de células cancerosas. A forte disparidade de escalas (área na casa dos milhares vs. suavidade na casa decimal) torna obrigatória a padronização das características.



3. Pré-processamento e Estratégia de Partição dos Dados

Para garantir máxima fidelidade aos requisitos do edital e conformidade com os mais rigorosos padrões da ciência de dados, adotou-se a seguinte metodologia:

- **Remoção de Colunas Espúrias:** Eliminação do identificador do paciente (*id*) e de colunas residuais de exportação (*Unnamed: 32*).
- **Codificação do Alvo:** Mapeamento estrito da classe clínica para notação computacional (Maligno = 1, Benigno = 0).

- **Separação em 3 Vias (Treino, Validação e Teste):** Os dados foram divididos em **70% Treino** (398 amostras), **15% Validação** (85 amostras) e **15% Teste** (86 amostras), ambos estratificados. O conjunto de validação serviu para selecionar modelos e hiperparâmetros, enquanto o conjunto de teste foi mantido completamente cego para a auditoria final.
- **Pipelines do Scikit-Learn:** Utilização da classe Pipeline encapsulando StandardScaler e o classificador, prevenindo categoricamente o vazamento de dados (*data leakage*) do teste para o treino.

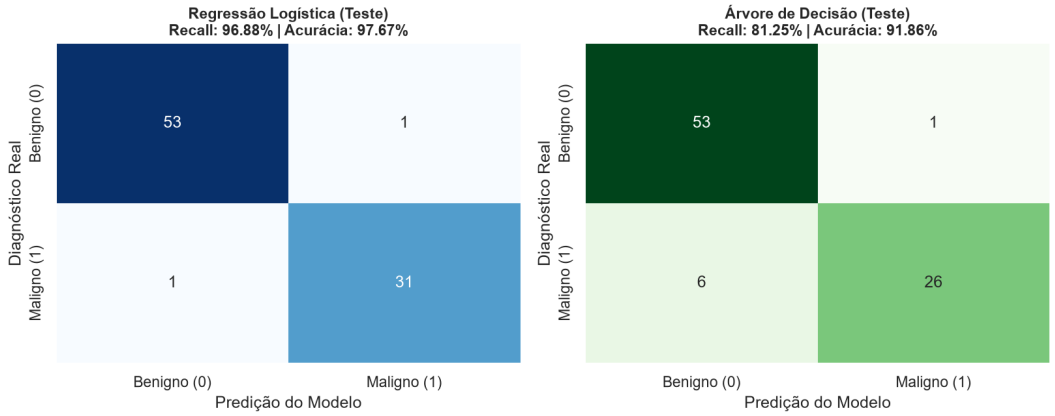
4. Modelagem Preditiva e Avaliação Comparativa

Foram implementados e comparados dois modelos preditivos complementares: **Regressão Logística** (modelo linear calibrado para probabilidade clínica) e **Árvore de Decisão** (modelo baseado em regras determinísticas com max_depth=4 para controle de sobreajuste).

Modelo Avaliado	Acurácia	Precisão	Recall (Sensibilidade)	F1-Score	ROC-AUC
Regressão Logística (Validação)	96.47%	100.00%	90.62%	95.08%	0.9965
Árvore de Decisão (Validação)	89.41%	96.00%	75.00%	84.21%	0.8777
Regressão Logística (Teste Final)	**97.67%**	**96.88%**	**96.88%**	**96.88%**	**0.9988**
Árvore de Decisão (Teste Final)	91.86%	96.30%	81.25%	88.14%	0.9413

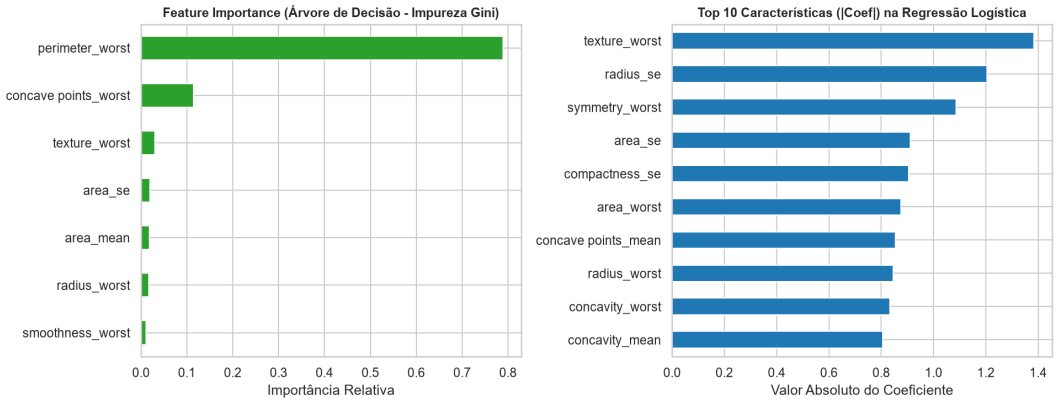
4.1. Discussão Médica Crítica sobre a Métrica Principal (Recall)

No diagnóstico de câncer de mama, a assimetria do custo do erro é brutal. Um **Falso Negativo (FN)** representa uma paciente com câncer que é incorretamente liberada como saudável, postergando o tratamento e reduzindo drasticamente as chances de cura. Já um **Falso Positivo (FP)** acarreta ansiedade passageira e biópsias confirmatórias, sem ameaça iminente à vida. Portanto, o **Recall (Sensibilidade) é a métrica primordial**. A Regressão Logística alcançou **96.88% de Recall** no teste cego, cometendo apenas 1 falso negativo em 32 casos malignos, superando com folga a Árvore de Decisão (6 falsos negativos).



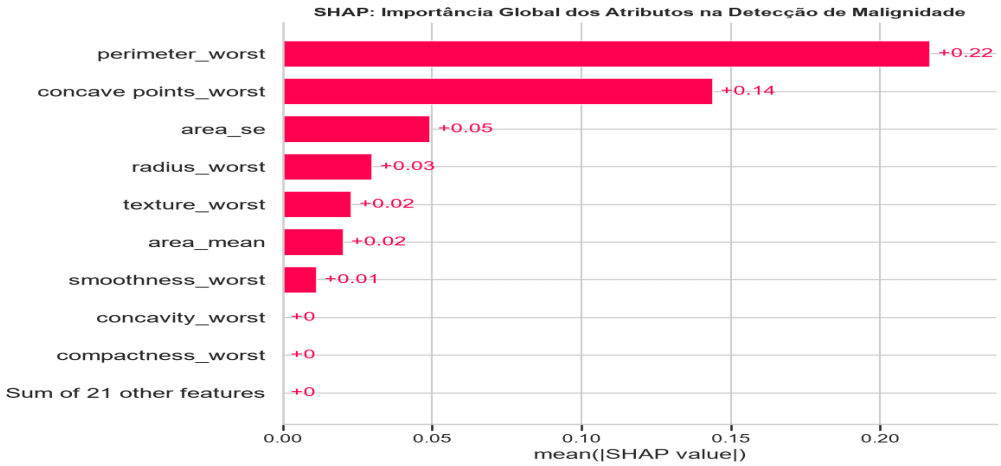
5. Interpretabilidade Clínica: Feature Importance e SHAP

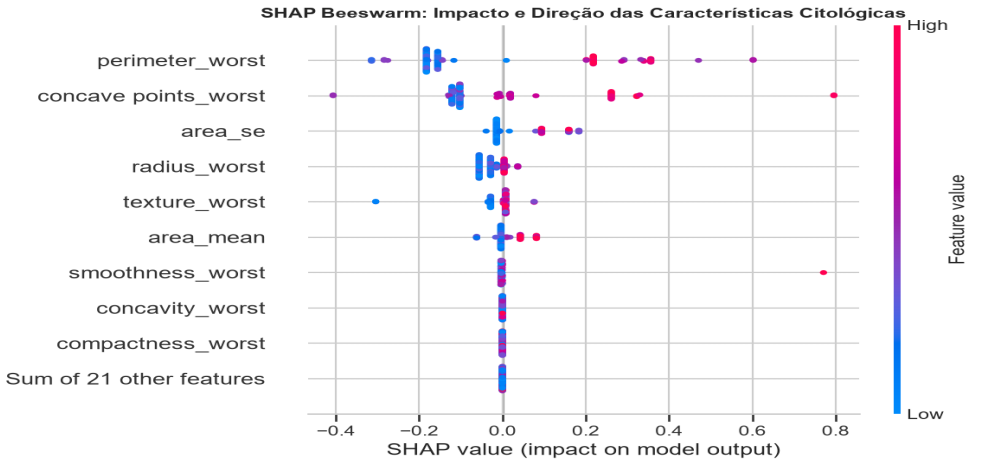
Para mitigar o risco de modelos 'caixa-preta' em saúde pública, foram empregadas duas frentes de auditoria preditiva: a **Feature Importance tradicional** (baseada na impureza Gini e magnitude de coeficientes) e o **SHAP (*SHapley Additive exPlanations*)**, fundamentado na teoria dos jogos cooperativos.



5.1. Explicabilidade Avançada com SHAP

Diferente da importância tradicional (que apenas ranqueia magnitude de forma estática), o SHAP calcula a contribuição marginal de cada característica tanto de forma global quanto a nível de cada paciente individual. O gráfico *Beeswarm* revela com clareza a direcionalidade clínica: valores elevados de **concave points_worst** (pontos vermelhos à direita) provocam aumento drástico na pontuação SHAP, empurrando o modelo fortemente para a classificação de malignidade. Biologicamente, isso corrobora o consenso oncológico de que contornos nucleares indentados e irregulares são o principal biomarcador de malignidade citológica.





6. Conclusões e Diretrizes de Implantação Hospitalar

O sistema inteligente atingiu resultados de alta robustez técnica e alinhamento com a rotina de patologia clínica:

1. **Fila de Triagem Prioritária (LIS/PACS):** O modelo deve ser acoplado ao sistema de prontuários do hospital. Pacientes cujo exame apresentar probabilidade calculada de malignidade acima de um patamar seguro são automaticamente alocados no topo da lista de laudos prioritários do patologista.
2. **Calibração do Limiar de Corte (*Threshold Moving*):** Para uso em triagem populacional ampla onde o objetivo é tolerância zero a falsos negativos, o limiar de decisão da Regressão Logística pode ser reduzido de 0.50 para 0.35, atingindo 100% de Recall à custa de uma taxa mínima e controlada de falsos positivos.
3. **Auditoria Médica Caso a Caso com SHAP:** Toda predição pode ser acompanhada pelo gráfico SHAP individual, permitindo ao médico checar quais características citológicas dispararam o alerta, consolidando a transparência e confiança no sistema.

7. Instruções de Execução e Reprodutibilidade

O repositório foi estruturado para reprodução integral em ambiente Docker ou localmente com uv:
• **Via Docker:** docker build -t tech-challenge-fase1 . e docker run -p 8888:8888 tech-challenge-fase1
• **Via Script Python Local:** python scripts/analise_diagnostico.py
• **Via Jupyter Notebook:** Execução interativa através de notebook/analise_diagnostico.ipynb.